

Trabajo Práctico Integrador — Maestría en Ciencia de Datos e Innovación Empresarial

Detección de Patologías en Radiografías de Tórax Veterinarias mediante Redes Neuronales Convolucionales

Un análisis del costo del error y la interpretabilidad clínica

Autoras: Lic. Lorena López & Lic. Gisela Poliak
Institución: Universidad CAECE (Junio 2026)

El Desafío Clínico: Fatiga, Variabilidad y la Necesidad de Triage

La interpretación de radiografías exige lectura cuidadosa. Depende de la experiencia del profesional y es vulnerable a la fatiga y alta carga de trabajo.

Flujo Diagnóstico Tradicional



Flujo Potenciado por IA



Puntos Clave



1. **Velocidad:** Acelerar el triage de casos urgentes.




2. **Consistencia:** Ofrecer una segunda opinión para reducir la variabilidad entre observadores.



3. **Priorización:** Destacar estudios con alta probabilidad de hallazgos (infiltrados pulmonares, cardiomegalia, etc.).

El Espacio de Datos: Restricciones y Distribución




Clase Patológica (1):
196 radiografías


Clase Normal (0):
245 radiografías

Estructura de Datos

Train
70% (308 imgs)

Val
15%

Test
15%

15% (66 imgs) 15% (67 imgs)

 **Nota Técnica:** Estrategias de Data Augmentation (rotaciones leves, zoom, brillo) aplicadas exclusivamente sobre el conjunto de entrenamiento para mitigar el sobreajuste y preservar la integridad del test.

Homogeneidad: Todas las imágenes corresponden a la misma especie anatómica para evitar sesgos de adquisición.

La Métrica Estrella: El Costo Asimétrico del Error


En el diagnóstico médico, la Exactitud (Accuracy) es engañosa.
Un modelo que prediga todo como "sano" ignorará a los pacientes críticos.

Matriz de Costo Clínico			
		Predicción de la IA	
		Sano	Patológico
Realidad	Sano	✓ Verdadero Negativo	Falso Negativo Error Crítico: Consecuencias irreversibles por ausencia de tratamiento.
	Patológico	Falso Positivo Falsa Alarma: Costo de revisión adicional y reevaluación.	✓ Verdadero Positivo

Objetivo Clínico: Maximizar la Sensibilidad (Recall). Priorizamos detectar la mayor cantidad posible de patologías reales, aceptando de manera consciente una mayor tasa de falsas alarmas.


El Enfrentamiento Analítico: Dos Enfoques frente a la Escasez de Datos

Enfoque 1: CNN desde Cero (Línea Base)



- **Estrategia:** Extracción clásica de características.
- **Complejidad:** ~423.000 parámetros entrenables.
- **Riesgo Clínico:** Alta probabilidad de memorización (overfitting) dado el dataset reducido de 441 imágenes.

Enfoque 2: Transfer Learning (MobileNetV2)




- **Estrategia:** Reutilización de una red preentrenada masivamente.
- **Fases de Entrenamiento:**
 1. Extracción (Base congelada).
 2. Fine-tuning sutil de capas superiores.
- **Ventaja:** Transfiere la comprensión geométrica general, adaptándola al dominio radiológico sin sobreajuste.

Resultados del Enfoque 1: La Ilusión de Aprender




Análisis del Colapso: Las curvas confirman un sobreajuste severo. El modelo memoriza el set de entrenamiento pero falla en generalizar.



El Engaño del Recall: El modelo clasifica TODAS las imágenes de test como patológicas. Logra un Recall del 100% de forma artificial por incapacidad de discriminar. (AUC = 0.451, peor que el azar). Modelo clínicamente inútil.

Resultados del Enfoque 2: El Poder de la Transferencia

Transfer learning — MobileNetV2



True label	Predicted label	
	ok	patologica
ok	31	6
patologica	7	23


Estabilidad de Aprendizaje: La base congelada extrae características rápidamente. El fine-tuning posterior consolida lo aprendido sin degradar la generalización.

Discriminación Real: La matriz demuestra un balance genuino y real capacidad de separación. (AUC = 0.852).

Síntesis de Desempeño: Transfer Learning Triunfa


Métricas en Conjunto de Test

Modelo	Umbral	Accuracy	Precision	Recall	AUC
CNN desde cero	0.5	0.448	0.448	1.000	0.451
Transfer Learning	0.5	0.806	0.793	0.767	0.852



Conclusión: La arquitectura **MobileNetV2** logra un equilibrio funcional entre atrapar patologías (Recall 0.767) y asegurar que las alertas sean reales (Precision 0.793). Se selecciona como el modelo definitivo para la calibración clínica.

Calibrando la Decisión: Priorizando al Paciente



Mecánica del Umbral

Por defecto, la red asigna patología si la probabilidad supera el 50%. Desplazar este umbral al 30% fuerza al modelo a capturar casos radiológicamente dudosos.

Impacto Clínico

Aumentamos el Recall a 0.867, minimizando los falsos negativos. Asumimos conscientemente la caída en Precisión porque es preferible revisar a un animal sano que ignorar a uno enfermo.

Abriendo la "Caja Negra": Transparencia mediante Grad-CAM



Imagen Original



Mapas de Características
(MobileNetV2)

Gradiente de Clase
Patológica (Ponderación)



Mapa de Calor Anatómico
(Grad-CAM)

El Problema:

La adopción clínica exige confianza. Un modelo diagnóstico no puede ser una caja negra ciega.




La Solución (Grad-CAM):

Interroga las últimas capas convolucionales para visualizar qué píxeles influyeron matemáticamente más en la decisión.

Objetivo de Auditoría:

Validar que la red observa estructuras anatómicas plausibles (pulmones, corazón) y no atajos espurios (bordes de placa, etiquetas).

Evidencia Clínica: El Acierto (Verdadero Positivo)



Evaluación del Mapa de Calor:

En este caso patológico (probabilidad = 0.61), la activación térmica se concentra nítidamente en la región torácica central, sobre los campos pulmonares y la silueta cardíaca.

Veredicto Forense:

El modelo apoya su decisión matemática en zonas anatómicamente plausibles, demostrando de forma transparente que aprendió señales clínicamente relevantes.


Anatomía del Error: Falsos Negativos y Positivos

Falso Negativo (Error Crítico, $p=0.36$)


Original



Grad-CAM



Pred: ok ($p=0.36$)




La activación térmica es dispersa y periférica (zona dorsal). Al no encontrar un patrón consolidado fuerte, la atención de la red se diluye y la probabilidad no logra superar el umbral clínico.

Falso Positivo (Falsa Alarma, $p=0.54$)


Original



Grad-CAM



Pred: patologica ($p=0.54$)



El mapa de calor se aferra a una región focal del tórax con mayor densidad radiológica, que la red confundió matemáticamente con un hallazgo limítrofe.

Conclusión Diagnóstica: Los errores del modelo radican en casos visualmente sutiles y zonas de densidad ambigua, no en fallas sistémicas por artefactos irrelevantes.

Conclusiones y Evolución del Sistema

Logro Principal: Se demostró que el Transfer Learning (MobileNetV2 con umbral ajustado a 0.30) supera la severa escasez de datos médicos, construyendo un **filtro de triage** interpretable que prioriza la sensibilidad.



1. Validación Cruzada (K-fold)

Robustecer las estimaciones métricas mitigando la varianza inherente de operar con un conjunto de test reducido (~67 imágenes).

Fase 1



2. Robustez de Origen

Entrenar con un corpus de imágenes provenientes de múltiples centros veterinarios y hardware para eliminar sesgos de equipo y técnica de adquisición.

Fase 2



3. Transición a Multiclase

Evolucionar el etiquetado binario genérico ('Patología') hacia una red capaz de clasificar afecciones específicas (infiltrados, derrames, cardiomegalia).

Fase 3